

Kishanlal Rajesh Leib

Data Scientist & KI-/Softwareentwickler

Aktuell: Masterarbeit in Kooperation mit der Amazone-Werk GmbH

Thema: Analyse von Service-Tickets mittels Large Language Models

Im Wohndorf 1 · 47119 Duisburg, Deutschland · +49 163 4168557

kishanlalkanojia10@gmail.com

LinkedIn · GitHub · Portfolio



Profil

Ich bin Data Scientist und KI-Entwickler mit einer Leidenschaft dafür, Dinge zu bauen, die in der Praxis wirklich funktionieren, von ersten Forschungsprototypen bis hin zu produktionsreifen Pipelines. Mein Schwerpunkt liegt aktuell auf LLM-Anwendungen, RAG-Systemen und dem Fine-Tuning von Transformer-Modellen. Derzeit schließe ich meinen Master in Digital Sciences an der TH Köln ab, mit einer Masterarbeit in direkter Zusammenarbeit mit der Amazone-Werk GmbH, bei der ich mit echten Industriedaten arbeite um herauszufinden, wie LLMs messbaren geschäftlichen Mehrwert schaffen können.

Technische Kenntnisse

KI/ML & NLP	Transformers, Fine-Tuning (PEFT/LoRA), RAG, LangChain, Dokumentenintelligenz, Evaluation (Ragas, NDCG, F1), OCR, ROSA, RAI
Programmierung	Python, Java, JavaScript, C, C++, SQL, PHP, Solidity
Frameworks	Django, Flask, FastAPI, Spring Boot, React, React Native, Node.js, Docker
Daten & ML-Tools	Pandas, Scikit-learn, PyTorch, TensorFlow, MLflow, DVC, FAISS, Chroma, Apache Spark, DBN-Modelle
Visualisierung	Matplotlib, Seaborn, Plotly, Dash, Knowledge Graphs, Neo4j, Heatmaps
Infrastruktur	AWS, Google Cloud, Microservices, REST-APIs, WebSockets, Kafka, LLM-Hosting
Datenbanken	MySQL, MongoDB, Firebase, SQLite, Snowflake, FHIR, Vektordatenbanken

Berufserfahrung

Data Scientist (Masterarbeit)

März 2025 – Juli 2026

Amazone-Werk GmbH & TH Köln, Deutschland

- Praktische Arbeit mit ca. **2 TB realen Industriedaten** Service-Tickets in Form von E-Mails, PDFs, Klartexten und strukturierten Logs mit insgesamt rund **1 Million Datenpunkten**.
- Entwicklung LLM-basierter Pipelines zur Extraktion von Geschäftserkenntnissen: Identifikation häufig defekter Maschinenkomponenten, Schätzung der anfallenden Reparaturkosten und Aufdeckung von Optimierungspotenzialen im Servicebereich.
- Da Amazone international tätig ist, liegen die Tickets in **mehreren europäischen und slawischen Sprachen** vor (Deutsch, Französisch, Russisch, Polnisch u. a.) die Handhabung dieser mehrsprachigen Komplexität ist ein zentraler Bestandteil der Arbeit.
- Forschungsfrage: *Wie können LLMs messbaren wirtschaftlichen Mehrwert für industrielle Service-Teams schaffen?* Inklusive ROI-Berechnungen und Kosten-Nutzen-Analyse KI-gestützter Automatisierung.
- Implementierung von Topic Modelling, Sentiment-Analyse und automatischer Ticket-Kategorisierung zur Optimierung von Service-Workflows.
- Aufbau von Dashboards zur Visualisierung von Service-KPIs und Kostenanalysen für das Management.

Data Scientist

Februar 2026 – Jun 2026

Sanguis GmbH, Deutschland

- Entwicklung und iteratives lokales Fine-Tuning verschiedener OCR-Ansätze sowie **Machine-Learning-Verfahren** zur Datenaufbereitung und zum Training für deutschsprachige Blutprodukt- und Lieferdokumente, resultierend in einer finalen Erkennungsgenauigkeit von über 95% auf 50 realen Testbildern.
- Implementierung KI-gestützter Verfahren, darunter **Retrieval-Augmented Generation (RAG)** zur kontextbasierten Informationsextraktion sowie **Prompt Engineering** und **Fine-Tuning großer Sprachmodelle (LLMs)** für medizinische Fachdokumente.

- Transformation von Altdatenformaten aus Universitätskliniken (u.a. Uni-Klinik Essen, Uni-Klinik Düsseldorf und Aachen) in **FHIR-konforme Datenstrukturen** zur systemübergreifenden Interoperabilität im Gesundheitswesen.
- Software- und Webentwicklung sowie Integration der OCR- und **RAG**-Lösung in eine bestehende mobile App auf Basis von **React Native** (Frontend) und **Flask** (Backend) unter strikter Einhaltung von DSGVO und Datensicherheitsanforderungen.
- Entwicklung zusätzlicher Features wie automatisierte Chargen- und Verfallsdatumsextraktion sowie Aufbereitung und Strukturierung medizinischer und prozessbezogener Daten, wodurch manuelle Dateneingaben um ca. 70% reduziert wurden.

Wissenschaftliche Hilfskraft (Data Science)

Januar 2025 – Dezember 2025

TH Köln, Köln, Deutschland

- Entwicklung und Evaluation experimenteller Suchsysteme in der **STELLA** Living-Lab-Infrastruktur mittels Interleaving-Techniken für die Echtzeitnutzerevaluation.
- Mitarbeit im **REANIMATOR**-Projekt: Aufbau von Dokumentenverarbeitungs-Pipelines mit **Docling** und **DeepSeek OCR** zur robusten Extraktion von Gleichungen, Abbildungen und Tabellen aus wissenschaftlichen Dokumenten.
- Prototypentwicklung von RAG-Pipelines mit **LangChain** und **FAISS**; Evaluation mit **Ragas** (Faithfulness, Answer Relevance, Context Recall).
- Vergleich aktueller Dokumentenrepräsentations- und Retrievalmethoden für die wissenschaftliche Literatursuche.

Softwareentwickler

Mai 2021 – Dez. 2021 und Sep. 2022 – Apr. 2023

Nexuses LTD, Mumbai, Indien

- Entwicklung konfigurierbarer medizinischer Untersuchungsformulare mit sicherer Datenspeicherung und Freigabefunktion für Gesundheitsdienstleister.
- Aufbau einer Vorlagenbibliothek für verschiedene medizinische Fachbereiche, die die Formularerstellung um 60 % beschleunigte.
- Implementierung von Datenvalidierung, Audit-Logging und REST-APIs zur EMR-Systemintegration.

Backend-Entwickler

Juli 2021 – Oktober 2021

Apex, Remote, Indien

- Erweiterung einer Bus-Buchungssapp um Echtzeit-Sitzzuweisung und Live-Tracking.
- Umstrukturierung des Backends auf eine Microservice-Architektur für Paketverfolgung, wodurch die Liefereffizienz um 25 % gesteigert wurde.
- Entwicklung von Admin-Dashboards für Plattformverwaltung und Echtzeit-Analysen.

Data-Science-Praktikant

Juli 2023 – Dezember 2023

Forschungsprojekt – Global Talent Attractiveness Index

- Entwicklung eines eigenen Modells zur Bewertung der Attraktivität von Ländern für hochqualifizierte Fachkräfte.
- Einsatz eines Multi-Kriterien-Entscheidungsrahmens (MCDA) mittels Analytischem Hierarchieprozess (AHP) sowie eines SARIMAX-Zeitreihenmodells zur Prognose von Talentströmen.
- Kernbefund: **Lebensqualität ist ein um 30 % stärkerer Prädiktor für Fachkräftemigration als das Gehalt** — mit konkreten Handlungsempfehlungen für nationale Talentstrategien.

Ausgewählte Projekte

LLM-gesteuertes autonomes Robotersystem

Sep. 2025 – Apr. 2026

Python, LLM, Computer Vision, ROS, AgileX Limo Roboter, RAI, ROSA

- Entwicklung eines multimodalen LLM-Systems zur sprach- und textkontrollierten Manipulation mit einem **AgileX Limo-COROT** Mobilroboter mit Greifer.
- Vergleich zweier LLM-zu-Roboter-Frameworks (**RAI** und **ROSA**) hinsichtlich ihrer Eignung zur Umwandlung natürlichsprachlicher Anweisungen in ausführbaren Robotersteuercode.
- Integration von Objekterkennung, räumlichem Schlussfolgern und Bewegungsplanung für autonome Navigation und Greifaufgaben.
- Fokus: Überbrückung der Lücke zwischen natürlichem Sprachverstehen und physischer Roboter Ausführung in einem realen cyber-physischen Laborumfeld.

Argument-Mining-Toolkit

März 2025 – Sep. 2025

Python, DeBERTa, PEFT/LoRA, IBM Argument Mining Datasets

- Open-Source-Tool zur automatischen Extraktion von Argumentstrukturen (Behauptungen, Prämissen) aus politischen Texten und Social-Media-Inhalten.
- Fine-Tuning von DeBERTa mit LoRA (parametereffizientes Fine-Tuning), mit **92 % F1-Score bei der Claim-Erkennung** — eine Verbesserung von 15 % gegenüber dem Baseline-Modell.
- GitHub: Horizontal-Labs

LLM-RAG-Evaluierungsframework

2025

LangChain, FAISS, Ragas, FastAPI, Chroma, Docker

- Aufbau einer umfassenden RAG-Pipeline mit mehreren Retrievalstrategien (dense, sparse, hybrid) und automatisierter Qualitätsbewertung via Ragas.
- Reduzierung der Halluzinationsrate um **40 %** durch verbessertes Retrieval und strukturierte Ausgabevalidierung mit Quellenreferenzierung.
- Containerisierung mit Docker für reproduzierbare und skalierbare Deployments.

Web-Information-Retrieval-System

2024 – 2025

Python, C++, Transformers, TIRA, ir_datasets

- Durchführung von Deep-Learning-Ranking-Experimenten auf großen IR-Datensätzen und Einreichung von Evaluierungsläufen auf der **TIRA**-Benchmarking-Plattform.
- Analyse transformer-basierter und hybrider neuronaler Rankingarchitekturen; Verbesserung der Retrievalgenauigkeit um **22 %** gegenüber BM25-Baselines.

MERN-Stack-E-Commerce mit KI-Empfehlungen

2023

React, Node.js, MongoDB, Express, Python, Scikit-learn

- Vollständige E-Commerce-Plattform mit kollaborativem Filtering und inhaltsbasierter Empfehlungs-Engine, die zu einer **Steigerung der Nutzerbindung um 35 %** führte.

Smart-IoT-Datenverarbeitungssystem

2022

Spring Boot, Kafka, MongoDB, Python, TensorFlow

- Entwicklung einer sicheren IoT-Pipeline zur Verarbeitung von **10.000+ Datenpunkten/Sekunde** mit Echtzeit-Anomalieerkennung und vorausschauender Wartung, wodurch Geräteausfälle um 25 % und die Pipeline-Latenz von 2 s auf 200 ms reduziert wurden.

Ausbildung

Master of Science in Digital Sciences

Sep. 2024 – Juli 2026

TH Köln, Köln, Deutschland

Schwerpunkt: Daten- und Informationswissenschaft

Masterarbeit: Analyse von Service-Tickets mittels Large Language Models (in Kooperation mit Amazone-Werk GmbH)

Bachelor of Engineering in Computer Engineering

Juli 2020 – Mai 2024

Vasantdada Patil Pratisthan's College of Engineering, Mumbai, Indien

Vertiefung Blockchain · CGPA: 9,35/10,0 · Abschluss mit Auszeichnung

Zertifikate

- **AlgoExpert** – Fortgeschrittenes algorithmisches Problemlösen Mai 2023
- **Frontend Expert** – Umfassende Webentwicklung Apr. 2023
- **Blockchain Expert** – Smart Contracts & DApps Juni 2023
- **HackerRank** – JavaScript Intermediate Juni 2022
- **HackerRank** – Node.js Intermediate 2022

Auszeichnungen & Erfolge

- **Guinness-Weltrekord** – Teilnahme an der weltweit größten diabetischen Augenuntersuchung Feb. 2019
- **1. Platz, Frontend-Entwicklung** – Technischer Hochschulwettbewerb Juni 2022
- **3. Platz im Jahrgang 2024** – Bachelor of Engineering 2024

Sprachkenntnisse

- **Deutsch:** Goethe-Zertifikat B1 (Zertifikat-Nr. 2021-AB1A-0002453918) verify.goethe.de/verify
- **Englisch:** C1 (Hören: 8 · Lesen: 7 · Schreiben: 6,5 · Sprechen: 6,5)
- **Hindi:** Muttersprache

Engagement & Außeruniversitäres

- **Leiter Öffentlichkeitsarbeit** – Entrepreneurship Development Cell (2022–2023): Leitung von Marketingkampagnen, Social-Media-Strategie und teamübergreifender Veranstaltungskoordination.
- **Klassensprecher** – Fachbereich Computer Engineering (2020–2024): Vertretung der Studierendeninteressen gegenüber Lehrenden und Hochschulverwaltung; Organisation von Workshops und technischen Veranstaltungen.
- **Präsentation vor Bundesminister** – Vorstellung von Forschungsprojekten und technologischen Innovationen auf einer Bundesveranstaltung.

Referenzen

Prof. Dr. Dietlind Zühlke	TH Köln dietlind.zuehlke@th-koeln.de
Benjamin Pusch	COO Sanguis GmbH b.pusch@sanguis-ag.de
Alam Shaikh	Direktor, Vasantdada Patil Pratisthan's College of Engineering principal@pvppcoe.ac.in
Mihir Kotwal	Geschäftsführer, Nexuses LTD mihir.kotwal@nexuses.com
Dr. René Leib	Geschäftsführer & Unternehmensberater (30+ Jahre Erfahrung) mail@drleib.de

Persönliche Angaben

Geburtsdatum: 20. März 2000
Staatsangehörigkeit: Deutsch
Alternativer Name: Kishanlal Rajesh Kanojia (Namensänderung infolge Adoption durch meinen deutschen Vater)